Inférence d'État de Règles (RSI) — Matériau Supplémentaire

Annexes A, B, C

Abdou-Raouf Atarmla

2026

Ce document contient le matériau supplémentaire associé au papier *Inférence d'État de Règles (RSI) : Un Cadre Bayésien pour la Surveillance de la Conformité dans les Domaines Régis par des Règles*. Il comprend le dictionnaire du dataset (Annexe A), les preuves complètes des théorèmes (Annexe B), et les détails de reproductibilité (Annexe C).

Contents

A Dictionnaire du Dataset : RSI-Togo-Fiscal-Synthetic v1.0 **2**
A.1 Vue d'ensemble . . . 2
A.2 Référence des colonnes . . . 2
A.3 Modèle de sous-déclaration . . . 3
A.4 Événement de changement réglementaire . . . 3
A.5 Structure en loi de puissance . . . 4

B Preuves Complètes des Théorèmes **4**
B.1 Preuve du Théorème 1 : Adaptabilité $O(1)$ . . . 4
B.2 Preuve du Théorème 2 : Consistance de Bernstein-von Mises . . . 5
B.3 Preuve du Théorème 3 : Convergence Monotone de l'ELBO . . . 6

C Détails de Reproductibilité **6**
C.1 Hyperparams de l'a priori . . . 6
C.2 Paramètres de l'inférence variationnelle . . . 7
C.3 Configurations des baselines . . . 7
C.4 Environnement de calcul . . . 7
C.5 Graines aléatoires . . . 7

A Dictionnaire du Dataset : RSI-Togo-Fiscal-Synthetic v1.0

A.1 Vue d'ensemble

Le dataset contient 2 000 entreprises synthétiques couvrant deux périodes réglementaires (2022–2024 et 2025), générées à partir des règles fiscales réelles de l'OTR. Chaque ligne est structurée en quatre couches :

1. **Caractéristiques des entreprises** : attributs observables de l'entité
2. **Vérité terrain latente** (`gt_*`) : le vrai état de la règle (a_i, c_i, δ_i), jamais accessible à RSI durant l'inférence
3. **Observations bruitées** (`obs_*`) : ce qu'un système fiscal observe réellement
4. **Étiquettes binaires** (`label_*`) : labels de conformité dérivés pour l'évaluation des baselines

A.2 Référence des colonnes

Colonne	Type	Description
Identifiants		
`enterprise_id`	chaîne	Identifiant unique de l'entreprise (ex. ENT_00001)
`period`	chaîne	Période réglementaire : `2022_2024` ou `2025`
Caractéristiques des entreprises		
`sector`	chaîne	Secteur économique (commerce, services, BTP, industrie, agriculture, restauration, transport)
`region`	chaîne	Région géographique au Togo (Lomé, Sokodé, Kara, etc.)
`ca_segment`	chaîne	Segment de CA : `informal` (<30M), `rsi` (30–100M), `reel` (≥100M)
`n_employes`	int	Nombre réel d'employés (distribution log-normale)
Vérité terrain latente (gt_*) — inaccessible à RSI durant l'inférence		
`gt_ca_reel`	flottant	Chiffre d'affaires annuel réel en FCFA
`gt_benefice_reel`	flottant	Bénéfice annuel réel en FCFA
`gt_tva_active`	int	1 si la règle TVA s'applique (CA $\geq$ seuil), 0 sinon
`gt_tva_compliance`	flottant	Taux de conformité TVA réel $c_i \in [0, 1]$, tiré d'un prior Beta
`gt_tva_due`	flottant	TVA théorique due (FCFA)
`gt_is_active`	int	1 si la règle IS s'applique (CA $\geq$ 100M FCFA)
`gt_is_compliance`	flottant	Taux de conformité IS réel $c_i \in [0, 1]$
`gt_is_due`	flottant	IS effectif dû (max de l'IS et de l'IMF) en FCFA
`gt_tpu_active`	int	1 si la règle TPU s'applique (CA $<$ 30M FCFA)
`gt_tpu_compliance`	flottant	Taux de conformité TPU réel $c_i \in [0, 1]$
`gt_irpp_susp_active`	int	1 si la suspension IRPP s'applique (salaire $<$ 900k, période 2023)
Observations bruitées (obs_*) — entrée de RSI		
`obs_ca_declare`	flottant	CA déclaré. Généré comme $\hat{x} = x \cdot \beta \cdot \varepsilon$ où $\beta \sim \text{Beta}(7, 3)$ capture la sous-déclaration systématique et $\varepsilon \sim \mathcal{N}(1, 0{,}045)$ le bruit de mesure. Ratio moyen $\mathbb{E}[\hat{x}/x] \approx 0{,}70$.

Suite page suivante

Colonne	Type	Description
`obs_tva_declaree`	flottant	Montant de TVA déclaré. Zéro si l'entité ne déclare pas ; distribué log-normalement autour de la TVA théorique sinon. `NaN` avec probabilité 0,18 (donnée manquante).
`obs_tva_assujetti_declare`	bool	Si l'entité s'est auto-déclarée assujettie à la TVA
`obs_is_declare`	flottant	IS déclaré. `NaN` avec probabilité 0,18.
`obs_benefice_declare`	flottant	Bénéfice déclaré. Typiquement 70% du bénéfice réel avec bruit. `NaN` avec probabilité 0,18.
`obs_retard_paiement_jours`	int	Délai de paiement en jours. Généré depuis Exponentielle(λ) où $\lambda = 5/(c_{\text{régime}}+0{,}1)$, avec $c_{\text{régime}}$ la conformité du régime applicable. Non-conformité élevée $\Rightarrow$ délais plus longs.
`obs_has_compte_bancaire`	bool	Si l'entité possède un compte bancaire formel. $P(\text{compte}) = 0{,}75 \cdot c + 0{,}20 \cdot (1-c)$ où c est la conformité du régime.
`obs_utilise_facturation_electronique`	bool	Si l'entité utilise la facturation électronique
`obs_a_ete_audite`	bool	Si l'entité a été auditée sur la période (taux de base 8%)
`obs_n_employes_declare`	int	Nombre d'employés déclaré ($\approx$ 85% de la vraie valeur)
`obs_ratio_sous_declaration`	flottant	Ratio CA déclaré / CA réel ($\hat{x}/x$)
`obs_tva_missing`	bool	Vrai si `obs_tva_declaree` est manquant
`obs_is_missing`	bool	Vrai si `obs_is_declare` est manquant
`obs_benefice_missing`	bool	Vrai si `obs_benefice_declare` est manquant
Étiquettes binaires (label_*) — utilisées uniquement pour l'évaluation des baselines		
`label_tva_non_conforme`	int	1 si TVA active et $c_{\text{TVA}} < 0{,}5$
`label_is_non_conforme`	int	1 si IS actif et $c_{\text{IS}} < 0{,}5$
`label_any_non_conforme`	int	1 si au moins l'un de : TVA non conforme, IS non conforme, ou conformité TPU $< 0{,}3$

A.3 Modèle de sous-déclaration

Le ratio de sous-déclaration est le mécanisme de bruit principal, reflétant le comportement fiscal réel en Afrique francophone. Pour chaque entreprise :

$$\hat{x} = x \cdot \underbrace{\beta}_{\text{systématique}} \cdot \underbrace{\varepsilon}_{\text{bruit}}, \quad \beta \sim \text{Beta}(7,3), \quad \varepsilon \sim \mathcal{N}(1,\, 0{,}045^2)$$

La distribution Beta(7,3) a une moyenne $7/10 = 0{,}70$ et concentre sa masse entre 0,55 et 0,85, conformément aux estimations empiriques des études fiscales en Afrique subsaharienne. Le terme de bruit gaussien capture les approximations comptables et les arrondis.

A.4 Événement de changement réglementaire

La période `2025` encode le relèvement du seuil TVA de 60M à 100M FCFA par la Loi n°2024-007 (30 décembre 2024). Les entreprises avec un CA réel dans $[60\text{M}, 100\text{M})$ FCFA passent de `gt_tva_active=1` (période 2022–2024) à `gt_tva_active=0` (période 2025), fournissant une expérience naturelle propre pour valider le Théorème 1 (adaptabilité $O(1)$).

A.5 Structure en loi de puissance

Le CA est tiré d'une distribution log-normale par segment, dont l'agrégat approxime une loi de puissance—la signature universelle des distributions de taille des firmes dans les économies de marché [Gabaix(2009)]. La structure en trois segments reproduit la concentration typique des marchés africains :

Segment	**Plage de CA**	**Part**
Informel (TPU)	$<$ 30M FCFA	60%
Intermédiaire (RSI)	30M – 100M FCFA	25%
Grand contribuable (IS/TVA)	$\geq$ 100M FCFA	15%

B Preuves Complètes des Théorèmes

B.1 Preuve du Théorème 1 : Adaptabilité $O(1)$

Théorème 1 (Adaptabilité $O(1)$ — complet)**.** *Pour toute mise à jour réglementaire $\mathcal{U}_k : \Theta_k \to \Theta'_k$, le coût de mise à jour RSI est $\mathcal{C}^{RSI}(\mathcal{U}_k) = O(1)$, indépendamment de $|\mathbf{D}|$ et de n. De plus, le posterior mis à jour est correctement normalisé, sans risque d'explosion de variance.*

Proof. **Étape 1 : Factorisation.** L'a priori RSI se factorise comme :

$$P(\mathbf{S}) = \prod_{i=1}^{n} P(s_i \mid \Theta_i)$$

Après la mise à jour $\mathcal{U}_k$, le nouvel a priori est :

$$P'(\mathbf{S}) = P(s'_k \mid \Theta'_k) \cdot \prod_{i \neq k} P(s_i \mid \Theta_i)$$

Étape 2 : Correction du posterior. Par le théorème de Bayes, le posterior avant mise à jour est :

$$P(\mathbf{S} \mid \mathbf{D}) = \frac{P(\mathbf{D} \mid \mathbf{S}) \cdot P(\mathbf{S})}{P(\mathbf{D})}$$

Après la mise à jour :

$$\begin{aligned} P'(\mathbf{S} \mid \mathbf{D}) &= \frac{P(\mathbf{D} \mid \mathbf{S}) \cdot P'(\mathbf{S})}{P'(\mathbf{D})} \\ &\propto P(\mathbf{S} \mid \mathbf{D}) \cdot \underbrace{\frac{P(s'_k \mid \Theta'_k)}{P(s_k \mid \Theta_k)}}_{\rho_k(\Theta_k, \Theta'_k)} \end{aligned}$$

Étape 3 : Complexité. Le facteur de correction ρ_k ne dépend que des formes paramétriques de $P(s_k \mid \Theta_k)$ et $P(s'_k \mid \Theta'_k)$. L'évaluation de deux distributions paramétriques (Bernoulli, Beta, Gaussienne) requiert un nombre constant d'opérations arithmétiques, d'où $O(1)$.

Étape 4 : Stabilité numérique. Le ratio ρ_k est appliqué au *noyau* (forme non normalisée) du posterior, et non à sa valeur absolue. La constante de normalisation est mise à jour comme :

$$P'(\mathbf{D}) = P(\mathbf{D}) \cdot \mathbb{E}_{P(\mathbf{S}|\mathbf{D})}[\rho_k]$$

Sous les familles conjuguées utilisées dans RSI (Beta-Binomiale pour c_i, Bernoulli pour a_i, Gaussienne pour δ_i), cette espérance est disponible en forme fermée. Le posterior reste donc une distribution de probabilité proprement normalisée après la mise à jour, sans explosion de variance. □

Corollaire 1.1 (Coût cumulatif sur T mises à jour)**.** *Sur T mises à jour réglementaires, les coûts totaux scalent comme :*

Méthode	*Coût total*
RSI	$O(T)$
ML supervisé (ré-entraînement complet)	$O(T \cdot \lvert\mathbf{D}\rvert \cdot E)$
PSL / MLN	$O(T \cdot \lvert\mathbf{D}\rvert \cdot n)$

où E dénote le nombre d'époques d'entraînement. RSI domine dans les environnements à forte fréquence réglementaire.

B.2 Preuve du Théorème 2 : Consistance de Bernstein-von Mises

Vérification des conditions de régularité.

C1 *Identifiabilité.* $P(\mathbf{D} \mid \mathbf{S}) \neq P(\mathbf{D} \mid \mathbf{S}')$ pour $\mathbf{S} \neq \mathbf{S}'$. *Vérification :* Chaque composante (a_i, c_i, δ_i) influence la vraisemblance via des mécanismes distincts. Des états distincts produisent des fonctions de vraisemblance distinctes.

C2 *A priori positif en la vérité.* $P(\mathbf{S}^*) > 0$. *Vérification :* L'a priori est un produit de Bernoulli, Beta et Gaussiennes, toutes à densité strictement positive sur leurs supports. Donc $P(\mathbf{S}) > 0$ pour tout $\mathbf{S} \in \mathcal{S}$.

C3 *Régularité de la vraisemblance.* $\log P(\mathbf{D} \mid \mathbf{S})$ est deux fois différentiable dans les composantes continues (c_i, δ_i). *Vérification :* Les fonctions de vraisemblance (log-gaussienne, exponentielle, Beta-Binomiale) sont lisses en leurs paramètres. La différentiabilité est héritée par le produit.

C4 *Information de Fisher finie.* $\mathcal{I}(\mathbf{S}^*)$ est finie et définie positive. *Vérification :* Sous C1 et C3, et sous réserve qu'aucune règle ne soit dégénérée (i.e., $c_i \notin \{0, 1\}$ et $a_i \in (0, 1)$), la matrice d'information de Fisher est définie positive.

Théorème 2 (Consistance BvM — complet)**.** *Sous les conditions C1–C4, quand $m \to \infty$:*

$$\sqrt{m}\big(\hat{\mathbf{S}}_m - \mathbf{S}^*\big) \xrightarrow{d} \mathcal{N}\big(0, \mathcal{I}(\mathbf{S}^*)^{-1}\big)$$

Proof. **Étape 1 : Convergence par la LGN.** Par la loi des grands nombres, pour des observations i.i.d. :

$$\frac{1}{m} \log P(\mathbf{D}_m \mid \mathbf{S}) \xrightarrow{p.s.} \mathbb{E}_{\mathbf{S}^*}[\log P(d \mid \mathbf{S})] = -\mathrm{KL}(P(\cdot \mid \mathbf{S}^*) \| P(\cdot \mid \mathbf{S})) + \mathrm{cst}$$

Ceci est maximisé en $\mathbf{S} = \mathbf{S}^*$ sous C1.

Étape 2 : Approximation gaussienne locale. Par un développement de Taylor au second ordre de $\log P(\mathbf{D}_m \mid \mathbf{S})$ autour de $\mathbf{S}^*$:

$$\log P(\mathbf{D}_m \mid \mathbf{S}) \approx \log P(\mathbf{D}_m \mid \mathbf{S}^*) + \nabla \ell_m^\top (\mathbf{S} - \mathbf{S}^*) - \frac{1}{2}(\mathbf{S} - \mathbf{S}^*)^\top \big[-\nabla^2 \ell_m\big](\mathbf{S} - \mathbf{S}^*)$$

Par la LGN, $-\frac{1}{m}\nabla^2 \ell_m \xrightarrow{p.s.} \mathcal{I}(\mathbf{S}^*)$ (C3, C4).

Étape 3 : Gaussianisation du posterior. En substituant dans le posterior :

$$\begin{aligned} P(\mathbf{S} \mid \mathbf{D}_m) &\propto \exp(\log P(\mathbf{D}_m \mid \mathbf{S})) \cdot P(\mathbf{S}) \\ &\approx \exp\Big(-\frac{m}{2}(\mathbf{S} - \mathbf{S}^*)^\top \mathcal{I}(\mathbf{S}^*)(\mathbf{S} - \mathbf{S}^*)\Big) \cdot P(\mathbf{S}) \end{aligned}$$

Étape 4 : Domination de l'a priori. Sous C2, $P(\mathbf{S}) > 0$ dans un voisinage de $\mathbf{S}^*$. Quand $m \to \infty$, le terme exponentiel concentre la masse en $\mathbf{S}^*$ à vitesse m, dominant l'a priori. Le posterior converge vers :

$$P(\mathbf{S} \mid \mathbf{D}_m) \xrightarrow{d} \mathcal{N}\left(\mathbf{S}^*, \frac{1}{m}\mathcal{I}(\mathbf{S}^*)^{-1}\right)$$

Le résultat suit par le changement de variable $\sqrt{m}(\mathbf{S} - \mathbf{S}^*)$. □

Corollaire 2.1 (Robustesse à l'a priori — complet)**.** *Soient $P_1(\mathbf{S})$ et $P_2(\mathbf{S})$ deux a priori RSI satisfaisant C2. Alors :*

$$\mathrm{TV}\big(P_1(\mathbf{S} \mid \mathbf{D}_m),\, P_2(\mathbf{S} \mid \mathbf{D}_m)\big) \to 0 \quad (m \to \infty)$$

Proof. Les deux posteriors convergent vers $\mathcal{N}(\mathbf{S}^*, m^{-1}\mathcal{I}(\mathbf{S}^*)^{-1})$ par le Théorème 2. Puisque la variation totale métrise la convergence faible sur $\mathbb{R}^d$, $\mathrm{TV}(P_i(\mathbf{S}|\mathbf{D}_m), \mathcal{N}(\cdot)) \to 0$ pour $i = 1, 2$, et le résultat suit par l'inégalité triangulaire. □

B.3 Preuve du Théorème 3 : Convergence Monotone de l'ELBO

Théorème 3 (ELBO Monotone — complet)**.** *Les mises à jour par ascension de coordonnées RSI produisent une séquence ELBO monotone non décroissante :* $\mathrm{ELBO}_{t+1} \geq \mathrm{ELBO}_t$ *pour tout* $t \geq 0$.

Proof. Rappelons la décomposition de l'ELBO :

$$\mathrm{ELBO}(\phi) = \mathbb{E}_{Q_\phi}[\log P(\mathbf{D} \mid \mathbf{S})] - \mathrm{KL}[Q_\phi(\mathbf{S}) \| P(\mathbf{S})] = \log P(\mathbf{D}) - \mathrm{KL}[Q_\phi(\mathbf{S}) \| P(\mathbf{S} \mid \mathbf{D})]$$

Puisque $\log P(\mathbf{D})$ est constant par rapport à ϕ, maximiser l'ELBO est équivalent à minimiser $\mathrm{KL}[Q_\phi \| P(\cdot|\mathbf{D})]$.

À l'itération t, la mise à jour pour le facteur i résout :

$$\phi_i^{(t+1)} = \arg\min_{\phi_i} \mathrm{KL}\big[Q_{\phi_i}(s_i) \cdot \prod_{j \neq i} Q_{\phi_j^{(t)}}(s_j) \parallel P(\mathbf{S} \mid \mathbf{D})\big]$$

La solution optimale est :

$$Q^*_{\phi_i}(s_i) \propto \exp\big(\mathbb{E}_{Q_{-i}}\big[\log P(\mathbf{D}, \mathbf{S})\big]\big)$$

Cette mise à jour ne peut que diminuer la divergence KL (ou la laisser inchangée), d'où $\mathrm{ELBO}_{t+1} \geq \mathrm{ELBO}_t$.

Puisque l'ELBO est borné supérieurement par $\log P(\mathbf{D}) < \infty$, la séquence converge. La limite est un point stationnaire de l'ELBO. □

Lemme 1 (Borne sur le gap variationnel)**.** *Soit* Q^*_ϕ *l'optimum champ-moyen. Alors :*

$$\mathrm{KL}[Q^*_\phi(\mathbf{S}) \| P(\mathbf{S} \mid \mathbf{D})] \leq \sum_{i=1}^{n} \mathrm{KL}[Q^*_{\phi_i}(s_i) \| P(s_i \mid \mathbf{D})]$$

Proof. Par la sous-additivité de la divergence KL sous l'hypothèse d'indépendance champ-moyen : $Q_\phi(\mathbf{S}) = \prod_i Q_{\phi_i}(s_i)$. □

C Détails de Reproductibilité

C.1 Hyperparams de l'a priori

Le Tableau 2 reportent les hyperparams de l'a priori $(\pi_i, \alpha_i, \beta_i, \sigma_i)$ utilisés pour chaque règle dans l'instanciation togolaise de RSI. Ces valeurs encodent la connaissance institutionnelle sur les taux de conformité historiques et la stabilité des règles.

Table 2: Hyperparams de l'a priori par règle. π_i : probabilité d'activation. (α_i, β_i) : a priori Beta sur la conformité ($\mathbb{E}[c_i] = \alpha/(\alpha + \beta)$). σ_i : écart-type du prior de dérive paramétrique.

Règle	**Description**	π_i	α_i	β_i	$\mathbb{E}[c_i]$	σ_i
R1_TVA	TVA 18%, seuil 60M / 100M FCFA	0,92	8,0	2,0	0,80	0,05
R2_IS	IS 29%, seuil 100M FCFA	0,88	6,0	4,0	0,60	0,03
R3_IMF	IMF 1% du CA	0,85	9,0	1,5	0,86	0,02
R4_TPU	Forfait secteur informel	0,70	3,0	7,0	0,30	0,15

Justification des choix de l'a priori.

- **R1_TVA** : Conformité a priori élevée ($\mathbb{E}[c_i] = 0{,}80$) car les entreprises assujettis à la TVA au Togo déposent généralement leurs déclarations, même si le montant est sous-estimé. Faible dérive ($\sigma = 0{,}05$) car le taux de 18% est stable sur la période.
- **R2_IS** : Conformité modérée (0,60) reflétant la complexité du calcul IS et les taux d'évasion plus élevés parmi les grandes entreprises.

- **R3_IMF** : Conformité élevée (0,86) car l'IMF est plus simple à calculer (1% du CA) et plus difficile à éviter.
- **R4_TPU** : Faible conformité (0,30) reflétant l'informalité bien documentée du secteur des micro-entreprises en Afrique subsaharienne. Dérive élevée ($\sigma = 0{,}15$) reflétant la forte incertitude sur ce segment.

C.2 Paramètres de l'inférence variationnelle

Table 3: Hyperparams de l'inférence variationnelle.

Paramètre	**Valeur**	**Justification**
Taux d'apprentissage η	1,5	Amplifie la mise à jour postérieure
Itérations max	150	Convergence empirique $\leq$ 10 itérations
Tolérance de convergence ε	10^{-5}	Seuil de variation ELBO
Seuil de décision τ	0,551	Optimisé pour le F1 sur l'ensemble de validation

C.3 Configurations des baselines

Table 4: Configurations des modèles baseline.

Modèle	**Paramètre**	**Valeur**
XGBoost	n_estimators	150
	max_depth	4
	learning_rate	0,1
	subsample	0,8
	random_state	42
MLP	hidden_layer_sizes	(64, 32, 16)
	activation	ReLU
	max_iter	200
	early_stopping	Vrai
	validation_fraction	0,1
	random_state	42
SBR	Seuil TVA (2022–2024)	60M FCFA
	Seuil TVA (2025)	100M FCFA
	Seuil d'alerte retard	90 jours

C.4 Environnement de calcul

Les expériences ont été exécutées sur un ordinateur de bureau standard (Windows 11, processeur Intel Core, 16 Go de RAM). Tout le code est implémenté en Python 3.11 en utilisant NumPy, SciPy et scikit-learn. Aucun GPU n'a été utilisé. La durée du pipeline expérimental complet est d'environ 5 à 10 minutes.

C.5 Graines aléatoires

Toutes les expériences utilisent `numpy.random.seed(42)` pour la reproductibilité. La génération du dataset utilise `numpy.random.default_rng(42)`.

References

[Gabaix(2009)] Gabaix, X. (2009). Power laws in economics and finance. *Annual Review of Economics*, 1(1):255–294.

[Blei et al.(2017)] Blei, D. M., Kucukelbir, A., et McAuliffe, J. D. (2017). Variational inference: A review for statisticians. *Journal of the American Statistical Association*, 112(518):859–877.

[van der Vaart(2000)] van der Vaart, A. W. (2000). *Asymptotic Statistics*. Cambridge University Press.